Estimación de parámetros y verificación de supuestos

Estimación de parámetros

Se mantuvo la estructura del modelo seleccionada previamente y se estimaron sus parámetros por mínimos cuadrados ordinarios. La respuesta es el logaritmo natural del precio de venta. La especificación incluye el tamaño, el piso, el momento de la venta, las ventas en bloque, la antigüedad, los parqueaderos en sótano y las escuelas cercanas, junto con los términos cuadrados e interacciones definidos en el apartado de estructura.

El ajuste utiliza 4.124 ventas y 22 parámetros, incluido el intercepto. La matriz de diseño tiene rango 22, por lo que los coeficientes están identificados. La varianza residual clásica estimada es 0,016046 en escala logarítmica. Se conservaron los centrados: logaritmo del tamaño respecto de 910 pies cuadrados, antigüedad respecto de diez años, año de venta respecto de 2012 para la interacción y parqueaderos en centenas respecto de 500. El año de referencia de las indicadoras es 2007.

Los errores estándar se calcularon agrupando las ventas por los 26 conjuntos residenciales. Esta decisión permite heterocedasticidad y dependencia dentro de cada conjunto y no modifica los coeficientes MCO. Se emplea la corrección finita de la covarianza agrupada de statsmodels y la referencia t con 25 grados de libertad. La inferencia supone independencia entre conjuntos y sigue siendo aproximada con este número de grupos. Los intervalos y contrastes posteriores deben conservar esta misma covarianza.

Tabla 1. Coeficientes y errores estándar del mismo modelo

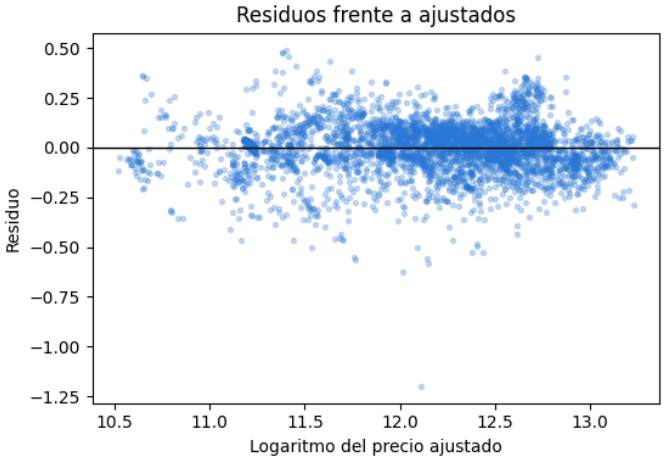
Término	Coeficiente	EE clásico	EE agrupado
Intercept	11.91598	0.01827	0.09318
C(YrSold)[T.2008]	0.05583	0.01631	0.02767
C(YrSold)[T.2009]	0.01061	0.01583	0.04411
C(YrSold)[T.2010]	0.08510	0.01565	0.02940
C(YrSold)[T.2011]	0.18105	0.01587	0.03176
C(YrSold)[T.2012]	0.26038	0.01607	0.04600
C(YrSold)[T.2013]	0.34052	0.01570	0.04896
C(YrSold)[T.2014]	0.46564	0.01557	0.05457
C(YrSold)[T.2015]	0.64357	0.01600	0.05511
C(YrSold)[T.2016]	0.64582	0.01577	0.04796
C(YrSold)[T.2017]	0.70938	0.01604	0.05640
logSize_c	0.80866	0.00645	0.05107
I(logSize_c ** 2)	-0.08998	0.00709	0.04478
Floor	0.00371	0.00028	0.00060
MonthSold	0.00594	0.00064	0.00124
Bloque	-0.47927	0.01033	0.03530
Antig_c	-0.02112	0.00046	0.00323
I(Antig_c ** 2)	0.00034	0.00003	0.00016
Antig_c:YrSold_c	0.00147	0.00009	0.00055
Parqueo_c	0.01926	0.00076	0.00416
logSize_c:Parqueo_c	-0.01973	0.00156	0.00641
N_SchoolNearBy_Total	-0.01339	0.00063	0.00449

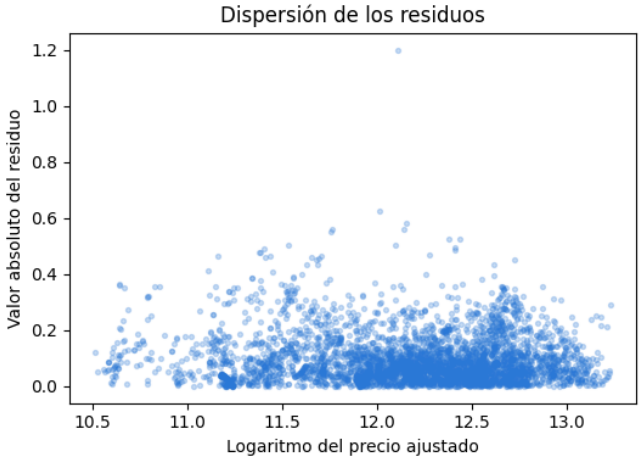
Verificación de los supuestos

Forma funcional y varianza

Los residuos se concentran alrededor de cero, pero su dispersión cambia a lo largo de los valores ajustados. Los gráficos frente al tamaño y la antigüedad muestran agrupamientos y diferencias en la posición y amplitud de los residuos. No constituyen evidencia suficiente para declarar completamente resuelta la estructura de la media. Las bandas verticales también reflejan valores repetidos de las explicativas.

Breusch-Pagan produce LM = 282,77 y p nominal = 1,01 x 10^-47, resultado contrario a la hipótesis de varianza constante. Su referencia clásica requiere cautela por la agrupación de las ventas, pero el contraste y la dispersión observada aconsejan no emplear errores estándar homocedásticos. Se mantiene la covarianza agrupada; esta elección ajusta la incertidumbre y no corrige por sí sola una media mal especificada ni atributos omitidos.

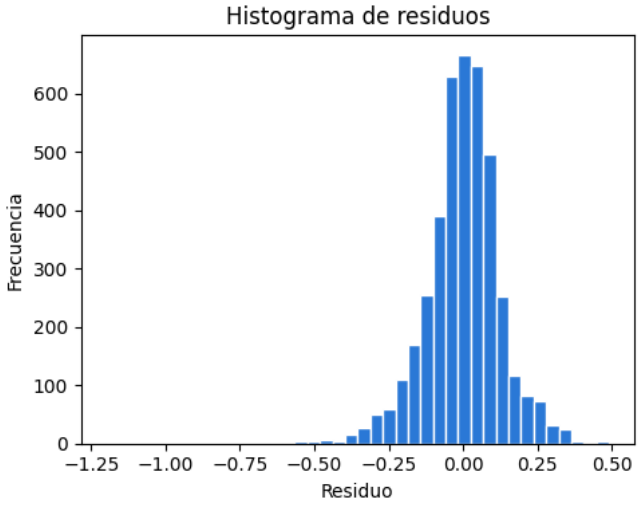


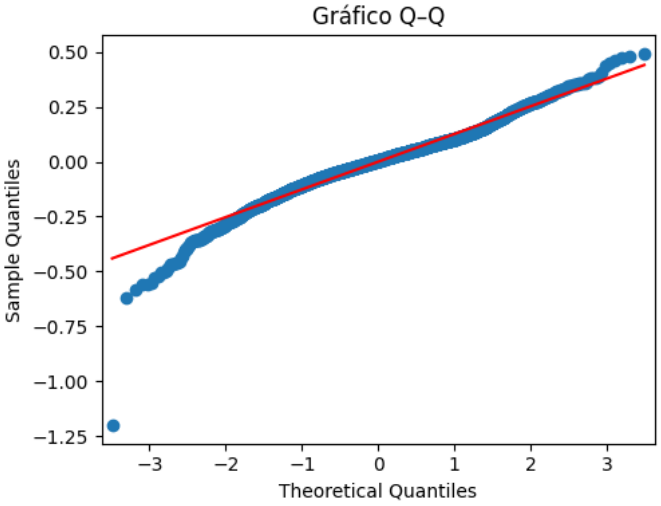


Normalidad

El histograma presenta una concentración marcada cerca de cero. El gráfico Q-Q se aparta de la recta de referencia en ambas colas, especialmente en la inferior. La asimetría es -0,50 y el exceso de curtosis 3,48. Jarque-Bera arroja 2.253,63, con un valor p nominal inferior a la precisión mostrada por el programa. El cero de la salida no se interpreta como una probabilidad exactamente nula.

Los resultados muestran desviaciones de normalidad marginal. La prueba no se usa de forma aislada ni como contraste ajustado por conglomerados. La normalidad no es necesaria para calcular MCO, aunque sí interviene en la inferencia clásica exacta; en este análisis se conserva la inferencia robusta agrupada y se reconocen sus límites con 26 conjuntos.

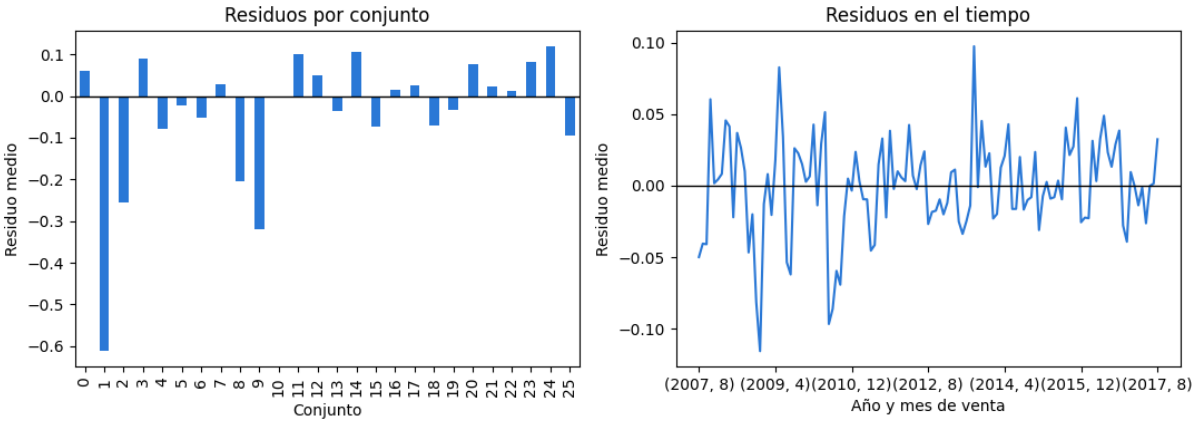




Dependencia y diferencias entre conjuntos

Persisten diferencias entre los residuos medios de los conjuntos. Las indicadoras de conjunto explican descriptivamente el 29,2 % de la variación residual. Este porcentaje no es una correlación intraclase ni una prueba formal de independencia. El gráfico mensual muestra oscilaciones alrededor de cero que, por sí solas, tampoco establecen autocorrelación.

La estructura de las ventas y los patrones residuales justifican considerar la agrupación. Se mantiene la covarianza por conjunto sin afirmar que la independencia entre conjuntos haya quedado demostrada. La media residual cercana a cero, consecuencia del ajuste con intercepto, no demuestra que el error tenga esperanza condicional cero. Los coeficientes se interpretan como asociaciones condicionadas a las variables incluidas, con posible confusión por atributos no observados.



Influencia y sensibilidad

Se señalaron 400 ventas, aproximadamente el 9,7 % de la muestra, mediante al menos uno de los umbrales exploratorios: residuo estandarizado absoluto mayor que tres, apalancamiento superior a 2p/n o distancia de Cook superior a 4/n. Las alertas no se consideran errores de registro ni criterios automáticos de eliminación.

La venta 3798 presenta precio de USD 54.867, tamaño de 910 pies cuadrados, piso 3, año de construcción 1980 y venta en octubre de 2014. Tiene residuo estandarizado -9,54 y Cook 0,05507, el máximo observado. Sus datos de estación y parqueaderos coinciden con registros identificados como construidos en 2014. La coincidencia merece revisión en la fuente, pero no permite corregir el año ni identificar automáticamente ambas agrupaciones como un mismo edificio.

Se comparó el ajuste completo con dos variantes de sensibilidad, sin modificar el modelo principal. Al retirar solo la venta 3798, el mayor cambio de los coeficientes equivale a 0,130 errores estándar agrupados del modelo completo; al retirar las tres ventas de su conjunto, a 0,192. Ambas matrices conservan rango 22. El resultado indica estabilidad de los coeficientes frente a estas exclusiones concretas, sin descartar otros posibles problemas de influencia. Se conserva la muestra completa.

Decisión para continuar

Se mantienen la fórmula logarítmica, las 4.124 ventas y la covarianza agrupada por conjunto. Se reportan heterocedasticidad, desviaciones de normalidad y patrones residuales entre conjuntos; no se declara que todos los supuestos estén satisfechos. Los apartados siguientes deben usar los objetos modelo_final, formula_final y train para mantener coherencia en bondad de ajuste, intervalos, pruebas e interpretación. El modelo del informe se distingue de la variante predictiva de Kaggle con efectos fijos y Box-Cox.